

RAG 检索增强生成

从原理到实践 · 示例演示文稿

什么是 RAG

- RAG = Retrieval-Augmented Generation（检索增强生成）
- 核心思想：先检索相关资料，再让大模型基于资料生成答案
- 优点：不用重新训练模型，就能掌握最新、私有、可引用的知识

RAG 的工作流程

- 1. 文档切块 (chunk)
- 2. 向量化 (embedding) 并存入向量数据库
- 3. 用户提问，问题向量化
- 4. 检索最相似的 Top-K 片段
- 5. 把片段拼进提示词，交给大模型生成答案

两个阶段

- 离线：建索引
- 收集文档 → 切块 → 向量化 → 存入向量库
- 在线：问答
- 问题向量化 → 检索 → 拼接 → 生成

RAG vs 微调

- 直接问模型：通用知识，易幻觉
- **RAG**：私有/最新知识，可引用来源
- 微调：固定风格与任务，成本高、更新难

常见工具栈

- 向量数据库：FAISS、Chroma、Milvus、Pinecone
- Embedding：OpenAI、BGE、M3E
- 编排框架：LangChain、LlamaIndex
- 重排序：Cohere Rerank、BGE-Reranker
- 大模型：DeepSeek、GPT、Claude、Qwen

应用场景

- 企业知识库问答
- 客服机器人
- 法律/医疗/金融助手
- 个人笔记助手
- 代码助手

谢谢

RAG Demo · 示例样本